

**IDENTIFIKASI SLEEP APNEA MELALUI PERUBAHAN GERAKAN
KEPALA DAN DADA MENGGUNAKAN HARRIS CORNER
DETECTION DAN RECURRENT NEURAL NETWORK**

PROPOSAL

Diajukan untuk Memenuhi Salah Satu Syarat
Matakuliah Tugas Akhir 1
Jenjang Strata 1 pada Program Studi Informatika
Universitas Jenderal Achmad Yani

Oleh:

Hizkia Syaukani

NIM. 3411 191 149



**PROGRAM STUDI INFORMATIKA
FAKULTAS SAINS DAN INFORMATIKA
UNIVERSITAS JENDERAL AHMAD YANI**

2022

LEMBAR PENGESAHAN

**IDENTIFIKASI SLEEP APNEA MELALUI PERUBAHAN GERAKAN
KEPALA DAN DADA SECARA REALTIME MENGGUNAKAN HARRIS
CORNER DETECTION DAN RECURRENT NEURAL NETWORK**

Cimahi,

Hizkia Syaukani

NIM. 3411 191 149

Menyetujui:

Pembimbing 1

Pembimbing 2

Dr. Esmeralda C. Djamal, S.T., M.T.

NID. 4121 276 70

Fatan Kasvidi, S.Kom., M.T.

NID. 4121 009 92

ABSTRAK

Sleep Apnea adalah keadaan tidur seseorang yang mengalami gangguan pernapasan dimana penderitanya seringkali mengalami berhenti bernapas saat tidur. Penelitian sebelumnya pada Sleep Apnea telah banyak dilakukan, yaitu identifikasi Sleep Apnea dengan defleksi kepala dan dada menggunakan ROI sebagai ekstraksi fitur pada defleksi kepala dan dada, lalu dilakukan klasifikasi dengan menggunakan Recurrent Neural Network dan Gated Recurrent Unit, namun memiliki kekurangan pada lokalisasi area tracking bagian kepala dan dada. Penelitian terkait dari melakukan pelacakan muka dengan menggunakan Harris Corner sebagai deteksi muka, lalu Haar Cascade sebagai identifikasi fitur dari muka tersebut dan dilakukan pelacakan dengan Algoritma Kanade Lucas Tomasi mendapatkan hasil yang baik, Namun memiliki kekurangan ketika kepala tersebut hilang maka akan diidentifikasi dari tahap awal. Penelitian ini akan membangun sebuah sistem yang dapat melakukan identifikasi terhadap Sleep Apnea dari seseorang yang tidur. Analisis tidur ini difokuskan pada perubahan arah vertikal kepala dan dada yang telah disegmentasi menggunakan Region of Interest (ROI) dengan menggunakan Algoritma Harris Corner sebagai deteksi fitur tiap framenya. Selanjutnya perubahan arah kepala dan dada setiap frame dianalisis menggunakan RNN-GRU masing-masing. Hasil analisis akan dibagi menjadi tiga kelas, yaitu "No Apnea", "Obstructive Sleep Apnea", dan "Central Sleep Apnea".

Kata Kunci — *Sleep Apnea, Region Of Interest, Recurrent Neural Network, Gated Recurrent Unit, Pergerakan Kepala dan Dada.*

1. Latar Belakang

Sleep Apnea adalah gangguan pernapasan yang setidaknya bertahan hingga sepuluh detik. Sleep Apnea ini didefinisikan sebagai penghentian aliran udara lengkap. Berbagai studi telah menghubungkan Sleep Apnea terhadap peningkatan penyebab dari penyakit kardiovaskular, diabetes, depresi, kelelahan di siang hari, dan kecelakaan kendaraan [1]. Seperti yang dinyatakan oleh *American Academy of Sleep Medicine* (AASM), Sleep Apnea mereduksi aliran udara sebanyak 90% sebanyak sepuluh detik [2].

Salah satu jenis yang sering terjadi pada Sleep Apnea adalah *Obstructive Sleep Apnea* (OSA), yang melibatkan obstruksi parsial atau lengkap pada saluran atas pernapasan sehingga menyebabkan amplitudo pernapasan dan saturasi oksigen darah menurun. Namun seseorang yang mengidap OSA cenderung tidak terdiagnosa, dikarenakan seseorang tersebut tidak menyadari bahwa Sleep Apnea sedang terjadi. Jenis lainnya dari Sleep Apnea yaitu *Central Sleep Apnea* (CSA), CSA terjadi karena gangguan neurologis. Pada saat terjadinya CSA, tidak ada pergerakan pada bagian tulang rusuk atau pada bagian perut dikarenakan kurangnya sinyal dari otak pada kontraksi otot. Ketika terjadi gangguan obstruksi pada seseorang, mereka akan didiagnosa diantara OSA dan CSA.

Salah satu alat untuk mengukur Sleep Apnea adalah *Pulse Oximetry*. *Pulse Oximetry* adalah teknik untuk mengukur konsentrasi oksigen pada darah. Kadang penurunan dari oksigen mendapatkan hasil dari gangguan yang berbeda. Tetapi sejak masalah terbesar dari OSA adalah pengurangan dari suplai oksigen pada otak, *Pulse Oximetry* cukup baik sebagai teknik deteksi OSA. Lalu ada *Acoustic*. Teknik *Acoustic* digunakan untuk mendeteksi OSA yang terdiri dari mikrofon dan pemrosesan suara. Mikrofon mencoba untuk mengidentifikasi suara dari pernapasan dari bayi, lalu sinyal suara memproses untuk mengidentifikasi anomali pada pola tersebut. Kelemahan dari teknik ini adalah ketika suara dari pernapasan sangat kecil dan kebisingan dari *background* suara dapat menyulitkan untuk menganalisa dari suara pernapasan [3]. Salah satu pendekatan klinis untuk membedakan OSA dan CSA adalah *Respiratory Inductance Plethysmography* (RIP). RIP mengukur gerakan dada dan perut dari dua pita transduser. RIP

merupakan bagian dari *Polysomnography* (PSG), yang menghubungkan lebih dari 20 sensor [4], sehingga membuat ketidaknyamanan pada seseorang yang tidur.

Penelitian dalam membedakan OSA dengan CSA telah banyak dilakukan, salah satunya yaitu identifikasi Sleep Apnea dengan defleksi kepala dan dada menggunakan *Region of Interest* (ROI) sebagai ekstraksi fitur pada defleksi kepala dan dada, lalu dilakukan klasifikasi dengan menggunakan *Recurrent Neural Network* dan *Gated Recurrent Unit*. Hasil yang didapatkan yaitu 88,89% pada *Single Region Head*, 94,44% pada *Single Region Chest*, dan 68,10% pada kedua regionnya [5]. Namun memiliki kekurangan pada *region* kepala karena masih terdeteksi pergerakan horizontal yang kurang signifikan ketika mengidentifikasi Sleep Apnea. Penelitian lain yang membedakan antara OSA dan CSA dengan menggunakan metode 3D-CNN mampu memberikan akurasi sebesar 95,4% dibandingkan dengan menggunakan 2DFFT-CNN yang hanya memberikan akurasi 89,7%[4]. Namun, hanya fitur dari video saja yang dianalisis dalam penelitian ini, sehingga penyimpangan tidak diproses, yang menyebabkan masalah pada memori yang digunakan dan menambah waktu pemrosesan.

Region of Interest (ROI) adalah wilayah yang akan menjadi fokus orang ketika sedang menonton gambar dan video. Wilayah ini lebih banyak menarik dari daerah lain, dan memiliki arti penting yang lebih tinggi[6]. Wilayah untuk mendeteksi dengan ROI juga telah dilakukan dengan menggunakan Novel Fused Activity yang terdiri dari Haar Classifier sebagai deteksi fitur, lalu Harris Corner digunakan sebagai identifikasi sudut kepala dan Kanade Lucas Tomasi sebagai pelacakan kepala tersebut mendapatkan akurasi sebesar 96,41% pada pelacakan kepala tersebut[7].

Penelitian lain yang menggunakan Haar Cascade Classifier pada deteksi keadaan mata tertutup dan terbuka telah dilakukan, Haar Cascade digunakan sebagai deteksi muka dan mata mendapatkan hasil sebesar 98,56% untuk deteksi mata dan 96,96% untuk deteksi keadaan mata[8]. Namun pada sebagian kasus *Classifier* tidak mengklasifikasi secara benar.

Penelitian terdahulu dalam melakukan proses pelacakan kepala menggunakan Harris Corner sebagai deteksi region muka, lalu digunakan Haar

Cascade sebagai identifikasi fitur dan Algoritma Kanade Lucas Tomasi sebagai pelacakan muka mendapatkan hasil yang baik[9]. Namun ketika kehilangan wajah maka identifikasi tersebut akan dimulai dari tahap awal.

Penelitian terdahulu dalam menggunakan Kanade-Lucas Tomasi pada *tracking* dan pengenalan wajah sebagai deteksi wajah mendapatkan hasil sebesar 92% dalam mendeteksi video pada Webcam[10]. Namun masih sulit mendeteksi dalam bagian yang sudah ditambah.

Penelitian terdahulu dalam melakukan deteksi pola pernapasan menggunakan *Persistent Luminous Impression Model* (PLIM) & *Novel Activity Template* untuk menampilkan defleksi bagian vertikal badan dan Sleep Apnea pada setiap *frame* secara episodik. Penelitian ini mampu mendeteksi Pola pernapasan normal sebesar 96,4% sleep apnea sebesar 91,4% dan defleksi bagian badan sebesar 98,8%[11]. Namun dalam penelitian tersebut adalah saat terjadi pergerakan pada tubuh secara kecil maka akan teridentifikasi bahwa seluruh sekuen dari pola pernapasan tersebut adalah Sleep Apnea.

Penelitian ini akan dibangun sebuah sistem yang dapat melakukan identifikasi Sleep Apnea dari perubahan arah vertikal kepala dan dada menggunakan Recurrent Neural Network Gated Recurrent Unit dimana Region of Interest (ROI) dengan Harris Corner sebagai deteksi sudut yang digunakan untuk mendeteksi defleksi vertikal bagian dada dan kepala pada setiap framenya lalu pola defleksi tersebut akan dianalisis menggunakan RNN-GRU sebelum diklasifikasikan menjadi tiga kelas yaitu “*No Apnea*”, “*Obstructive Sleep Apnea*”, dan “*Central Sleep Apnea*”.

2. Rumusan Masalah

Pemrosesan video pada identifikasi Sleep Apnea membutuhkan identifikasi pergerakan dari lokalisasi area dan *tracking* dari pergerakan kepala dan dada. Namun pada identifikasi ini terjadi perbedaan dari area efektif pada *region* ketika adanya pergerakan. Oleh karena itu diperlukan sebuah optimalisasi dari pelacakan pada perubahan gerakan kepala dan dada tersebut.

3. Batasan Masalah

Terdapat beberapa batasan masalah dalam penelitian ini, yaitu:

- a. Kamera yang digunakan berupa kamera RGB atau kamera Inframerah.
- b. Subjek yang direkam hanya satu orang saja.
- c. Subjek yang direkam tidak menggunakan selimut

4. Tujuan Penelitian

Penelitian ini bertujuan untuk membuat sebuah sistem yang dapat mengidentifikasi gangguan Sleep Apnea menggunakan Harris Corner dan Recurrent Neural Network dimana Harris Corner digunakan untuk mendeteksi bagian sudut kepala dan dada, lalu pola perubahan gerakan pada kepala dan dada akan diidentifikasi melalui Recurrent Neural Network.

5. Luaran dan Manfaat Penelitian

5.1 Luaran

Sistem dapat mengidentifikasi Sleep Apnea menggunakan video dan mengklasifikasikan video tersebut menjadi tiga kelas, yaitu “*No Apnea*”, “*Obstructive Sleep Apnea*”, dan “*Central Sleep Apnea*”.

5.2 Manfaat

Sistem dapat memprediksi Sleep Apnea berbasis video, serta diharapkan pemrosesan video ini memberikan kontribusi ilmiah dalam bidang pengetahuan berupa metode yang diusulkan.

6. Tinjauan Pustaka

Tinjauan pustaka menjelaskan penelitian terdahulu yang berkaitan dengan identifikasi dari Sleep Apnea. Metode terdiri dari Region of Interest (ROI) yang digunakan untuk mengidentifikasi dari pergerakan dada dan kepala, lalu Recurrent Neural Network (RNN) digunakan untuk mempelajari pola dari pergerakan pada kepala dan dada.

6.1 Region Of Interest (ROI)

Region of Interest (ROI) adalah area yang menjadi fokus seseorang saat melihat gambar dan video. Area ini lebih menarik daripada area lainnya dan memiliki arti lebih penting.[6]

Alur dari algoritma deteksi ROI yang diusulkan. (a) *Feature Detection* dengan menggunakan Haar Classifier (b) *Feature Extraction* dengan menggunakan

Harris Corner, dan (c) *Feature Tracking* dengan menggunakan Algoritma Kanade-Lucas Tomasi.[9]

6.1.1 Haar Classifier

Algoritma Viola-Jones didasari dari *haar-feature of human face*. Proses ini terdiri dari menggunakan *haar-like feature of human face* untuk mendeskripsikan sifat umum dari wajah. Menetapkan fitur dari gambar integral. Dengan kata lain, mendapatkan beberapa jenis persegi panjang dari fitur yang berbeda yang didasari dari citra integral. Algoritma Adaboost digunakan untuk melatih dan mengklasifikasikan hirarki. *Haar-like feature* hanya berhubungan dengan nilai piksel dalam satu *region* persegi panjang, nilai dari fitur adalah perbedaan antara *region* putih dan jumlah nilai piksel dari *region* hitam [9]. Haar Feature dapat digunakan dengan persamaan(2).

$$ii(x, y) = \sum_{x' \leq y'} i(x' y') \quad (2)$$

dimana $ii(x, y)$ merupakan citra integral dan $i(x' y')$ merupakan citra original [5].

6.1.2 Harris Corner Detection

Algoritma Harris didasari berdasarkan dari dua poin gradien piksel yang menentukan poin piksel adalah sudut atau bukan[12], ide dasar dari mengobservasi *window* dari tambalan gambar yang bisa menghasilkan variasi yang berbeda ketika bergerak. Ini dapat dijadikan persamaan matematis antara fungsi *window*, *sliding window* dan intensitas dengan persamaan(1).

$$E(u, v) = \sum_{x, y} w(x, y) [I(x + u, y + v) - I(x, y)]^2 \quad (1)$$

dimana E adalah perbedaan diantara original dan pergerakan *window*, u adalah pemindahan dari arah x , v adalah pemindahan dari arah y , $w(x, y)$ adalah *window* pada posisi (x, y) . ini bertindak sebagai *mask* untuk memastikan bahwa hanya *window* yang diinginkan saja yang digunakan. I adalah intensitas dari citra pada posisi (x, y) , $I(x+u, y+v)$ adalah intensitas dari *window* yang bergerak. $I(x, y)$ intensitas yang original.[13]

6.1.3 Kanade-Lucas Tomasi

Algoritma Kanade Lucas Tomasi (KLT) digunakan sebagai metode pelacakan titik fitur. Algoritma KLT ditemukan oleh Lucas dan Kanade dan dikembangkan kembali oleh Tomasi bersama Kanade. Algoritma ini digunakan

untuk mendeteksi titik-titik yang memiliki tekstur yang tepat untuk melacak titik yang dibutuhkan yang disebut *good feature to track*.

Pertama, KLT menghitung perpindahan titik yang dilacak dari satu frame ke frame lain pada deretan citra masukan, hasil perhitungan perpindahan ini, akan sangat mudah untuk menghitung pergeseran kepala pada setiap frame. KLT melacak gerakan kepala dan dada dalam dua langkah sederhana, pertama menemukan titik fitur yang dapat dilacak di frame pertama dan kemudian melacak fitur yang terdeteksi di frame berikutnya dengan menggunakan perhitungan perpindahan.

Asumsikan bahwa salah satu titik sudut awal adalah (x,y) . Kemudian pada frame berikutnya, jika terjadi perpindahan oleh beberapa vektor variabel disimbolkan dengan Persamaan 4 [14].

$$[b1(x,y), b2(x,y), b3(x,y), \dots bn(x,y)] \quad (3)$$

maka titik yang dipindahkan dari frame berikutnya akan menjadi penjumlahan dari titik awal dan vektor yang dipindahkan koordinat titik baru dijelaskan pada Persamaan 5 dan 6.

$$x' = x + b1(x,y) \quad (4)$$

$$x' = x + b2(x,y) \quad (5)$$

Maka, perpindahan yang terjadi saat ini dihitung untuk setiap koordinat yang ada. Dengan ini, kami menggunakan fungsi warp (*warp function*) yang merupakan fungsi dengan koordinat dan parameter yang dilambangkan pada Persamaan 7.

$$W(x;p) = (x + b1; x + b2) \quad (6)$$

Fungsi warp digunakan untuk memperkirakan formasi dari setiap titik. Pada setiap pelacakan yang dilakukan di setiap frame, koordinat pada setiap titik fitur disimpan sebagai data yang akan dihitung untuk menstabilkan ROI kepala dan dada pada setiap frame.

6.2 Recurrent Neural Network (RNN)

RNN dirancang untuk memproses data sekuensial. Data sekuensial (sequence data) adalah data yang saling terkait satu sama lain, atau berurutan, di mana data diproses secara berurutan dan data dalam urutan terkait erat satu sama lain. Banyak

karya teoretis dan ekperimental telah diterbitkan tentang jenis RNN ini, banyak dari mereka melaporkan hasil yang luar biasa pada sistem atau aplikasi yang dimana datanya berupa sekuensial.[15]

RNN menggunakan neuron dari jaringan tersebut dimana masing-masing neuron memberikan informasi kepada neuron berikutnya yang dihubungkan dengan bobot. Hubungan satu *cell* ke *cell* selanjutnya membuat jaringan dapat menyimpan informasi pada memori, sementara yang memberikan pengaruh besar dalam cara input adalah menghadirkan kembali nilai masa lalu ke dalam jaringan tersebut. Dilihat dari penjabaran tersebut setiap jaringan mengambil nilai input x kemudian dimasukkan ke dalam *cell* yang berisi *gate* yang akan diperbarui setiap kali jaringan tersebut membaca masukan baru sehingga menghasilkan output pada setiap waktu.

6.2.1 Gated Recurrent Unit (GRU)

Masalah muncul akibat ketergantungan dalam proses jangka panjang RNN ketika saat melakukan *propagation*, RNN akan kehilangan nilai untuk memperbarui bobot jaringan atau disebut Gradien. Untuk mengatasi masalah ingatan jangka pendek terdapat dua arsitektur yang populer digunakan yaitu, Long-Short Term Memory (LSTM) dan Gated Recurrent Units (GRU) yang dapat mengingat ingatan lebih panjang. LSTM mengurangi masalah gradien dengan menerapkan konstan aliran kesalahan melalui "*constant error carrouseles*" di dalam sel unit yang terdiri dari gerbang *input*, *forget* dan *output*. Sedangkan GRU hanya memiliki gerbang *reset* dan *update*.

GRU secara adaptif mewakili dependensi data sekuensial dikarenakan GRU memiliki *recurrent unit* seperti LSTM yang menangkap aliran pola dalam *recurrent unit*, tetapi tidak memiliki *isolated cell* untuk menangkap urutan.

Setiap sel GRU memiliki konfigurasi yang terdiri dari gerbang *reset* dan *update* serta operasi *tensor* yang lebih cepat. Gerbang *update* berfungsi untuk mempertahankan, menambah dan melupakan informasi yang tidak dibutuhkan lagi sekaligus sebagai bahan masukan ke sel selanjutnya. Sementara gerbang *reset* berfungsi untuk menentukan seberapa banyak informasi yang lalu akan dibuang. Aktivasi h_t^j dari GRU pada waktu t adalah interpolasi linier antara aktivasi sebelumnya h_{t-1}^j dan aktivasi kandidat \bar{h}_t^j dengan Persamaan 10 [16].

$$h_t^j = (1 - z_t^j) h_{t-1}^j + z_t^j \tilde{h}_t^j \quad (7)$$

Dimana gerbang update z_t^j memutuskan berapa banyak unit yang akan dilakukan aktivasi, atau kontennya. Gerbang *update* dihitung dengan Persamaan 11.

$$z_j = \sigma([W_z x]_j + [U_z h_{(t-1)}]_j) \quad (8)$$

Dimana σ merupakan fungsi sigmoid, dan $[\cdot]_j$ adalah elemen vektor ke- j . x dan h_{t-1} adalah masukan dari *hidden state* sel sebelumnya. Serta W dan U merupakan bobot yang dipelajari. Aktivasi kandidat \tilde{h}_t^j dihitung mirip dengan *recurrent unit* dapat dilihat pada Persamaan 12.

$$h_t = \tanh(W_{xt} + U (r_t \odot h_{(t-1)})) \quad (9)$$

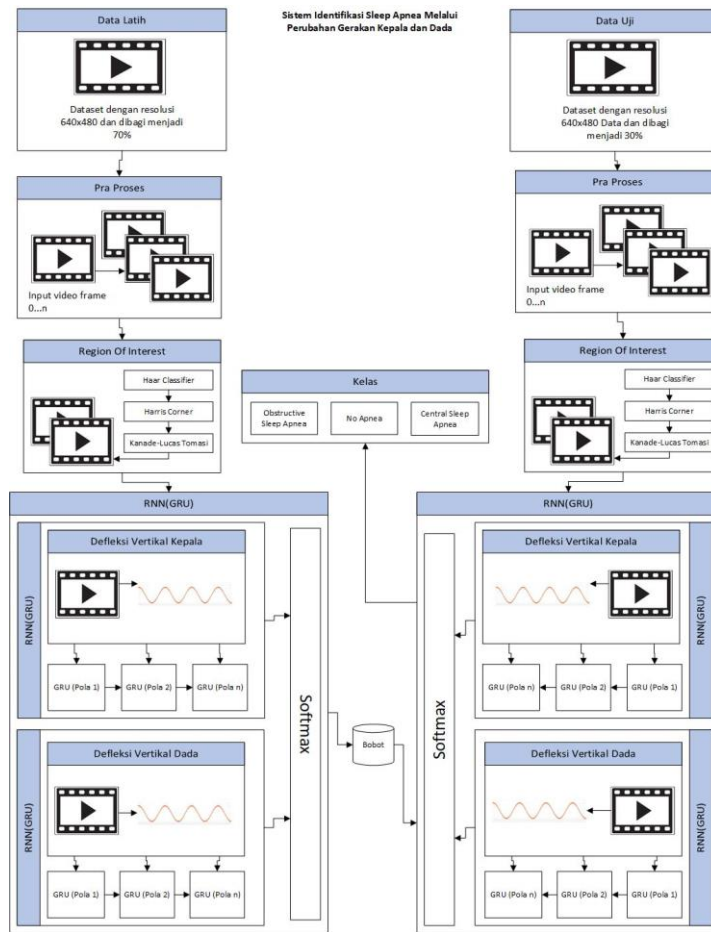
Dimana z_t^j adalah himpunan gerbang *reset* dan \odot merupakan perkalian elemen. Saat (r_t^j mendekati 0), gerbang *reset* secara efektif membuat unit bertindak seolah-olah sedang membaca ar ai pertama dari urutan input, memungkinkannya untuk melupakan keadaan yang dihitung sebelumnya. Gerbang *reset* r_t^j dihitung mirip dengan gerbang *update* dengan Persamaan 13.

$$r_j = \sigma([W_r x]_j + [U_r h_{(t-1)}]_j) \quad (10)$$

Fungsi aktivasi Softmax menghitung probabilitas setiap bobot *recurrent*, sehingga mempengaruhi ukuran fungsi *loss* dan memastikan penyebaran yang efektif dari gradien. Setelah pemrosesan Softmax, nilai diubah menjadi probabilitas.

7. Metode Penelitian

Pada penelitian ini akan dilakukan enam tahapan untuk pembuatan sistem identifikasi sleep apnea. Diawali dengan perolehan data dari penelitian sebelumnya hingga diakhiri dengan pelaporan dan publikasi ilmiah di bidang informatika. Pada Gambar 1 terdapat diagram blok metode penelitian



Gambar 1 Diagram Blok

Tahap pertama dalam penelitian ini adalah perolehan data, data latih diambil dari Figshare Repository[17] berukuran 640x480 dengan jumlah frame 30 fps. Dataset ini berisi 28 video dari 12 subjek yang diteliti. Video ini berdurasi 30 sampai 42 detik. Dataset ini akan dibagi menjadi 70% untuk data latih dan 30% untuk data uji.

Tahap kedua merupakan pra proses video yang merupakan proses video masukkan diolah menjadi *frame by frame*, dan dilakukan perubahan ukuran resolusi menjadi 640x480 untuk mendapatkan fokus dari ROI.

Tahap ketiga yaitu penggunaan metode ROI dan RNN(GRU). ROI digunakan untuk mengambil *region* dari kepala dan dada, dengan tiga tahapan, yaitu dengan Haar Classifier untuk mengambil pada *region* dari dada dan kepala dengan dimensi 3x3 untuk kepala dan 4x3 untuk dada, lalu menggunakan persamaan (1) mendapatkan *region* kepala dan dada pada setiap *frame*-nya, lalu Harris Corner

digunakan untuk mendapatkan sudut-sudut dari bagian kepala dan dada. Harris Corner ini dengan menggunakan persamaan (2), lalu digunakan metode Kanade-Lucas Tomasi untuk mendapatkan titik fitur yang diberikan.

Setelah itu dilakukan Proses RNN-GRU untuk mengolah data pergerakan arah tersebut. Pada setiap pola pergerakan arah akan dimasukkan kedalam setiap sel GRU. Tiap sel GRU akan melakukan operasi perkalian dan penggabungan nilai vektor melalui gerbang *update* dan *reset* dengan fungsi aktivasi Sigmoid di bagian akhir setelah menghasilkan keluaran tiap sel. Hasil dari urutan citra yang didapatkan akan diklasifikasikan oleh GRU menjadi tiga kelas, yaitu “No Apnea”, “Obstructive Sleep Apnea”, dan “Central Sleep Apnea”.

Tahap keempat adalah perancangan dan pengembangan perangkat lunak menggunakan bahasa pemrograman Python untuk implementasi rancangan.

Tahap kelima adalah pengujian dan evaluasi dari hasil perancangan dengan memodifikasi konfigurasi untuk mendapatkan hasil yang lebih sesuai.

Tahap keenam adalah bagian akhir yaitu pembuatan laporan dan publikasi seminar informatika

8. Jadwal Penelitian

Jadwal penelitian yang akan dilakukan dapat dilihat pada Tabel 1.

Tabel 1 Jadwal Penelitian

No.	Kegiatan	Bulan Ke-1				Bulan Ke-2				Bulan Ke-3				Bulan Ke-4			
	Minggu Ke	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
1.	Perolehan data																
2.	Pra proses data																
3.	Pemrosesan data dengan ROI & RNN(GRU)																
4.	Perancangan dan pengembangan perangkat lunak																

Computation System and Information Technology for Sustainable Solutions, CSITSS 2016, pp. 1–6, 2016, doi: 10.1109/CSITSS.2016.7779430.

- [8] N. L. Fitriyani, C. K. Yang, and M. Syafrudin, “Real-time eye state detection system using haar cascade classifier and circular hough transform,” *2016 IEEE 5th Global Conference on Consumer Electronics, GCCE 2016*, pp. 5–7, 2016, doi: 10.1109/GCCE.2016.7800424.
- [9] C. Lan, C. Huang, X. Guo, L. Zhang, and C. Han, “Facial feature detection and tracking based on the video image,” *Proceedings - 2017 International Conference on Computer Technology, Electronics and Communication, ICCTEC 2017*, pp. 1103–1107, 2017, doi: 10.1109/ICCTEC.2017.00241.
- [10] N. H. Barnouti, M. H. N. Al-Mayyahi, and S. S. M. Al-Dabbagh, “Real-Time Face Tracking and Recognition System Using Kanade-Lucas-Tomasi and Two-Dimensional Principal Component Analysis,” *ICOASE 2018 - International Conference on Advanced Science and Engineering*, pp. 24–29, 2018, doi: 10.1109/ICOASE.2018.8548818.
- [11] C. W. Wang, A. Hunter, N. Gravill, and S. Matusiewicz, “Unconstrained video monitoring of breathing behavior and application to diagnosis of sleep apnea,” *IEEE Transactions on Biomedical Engineering*, vol. 61, no. 2, pp. 396–404, 2014, doi: 10.1109/TBME.2013.2280132.
- [12] S. Guiming and S. Jidong, “Multi-Scale Harris Corner Detection Algorithm Based on Canny Edge-Detection,” *2018 IEEE International Conference on Computer and Communication Engineering Technology, CCET 2018*, pp. 305–309, 2018, doi: 10.1109/CCET.2018.8542206.
- [13] M. Babiker, O. O. Khalifa, K. K. Htike, A. Hassan, and M. Zaharadeen, “Harris corner detector and blob analysis featuers in human activty recognetion,” in *2017 IEEE 4th International Conference on Smart Instrumentation, Measurement and Application (ICSIMA)*, 2017, pp. 1–5.
- [14] L. Kanade, Tomasi, “Continous Inferior Vena Cava Diameter Tracking Through An Iterative Kanade-_{Lucas}-Tomasi-Based Algorithm,” *Ultrasound in Medicine and Biology*, vol. 44, no. 12, pp. 1–9, 2018, doi: 10.1016/j.ultrasmedbio.2018.07.022.

- [15] A. Sherstinsky, “Fundamentals of Recurrent Neural Network (RNN) and Long Short-Term Memory (LSTM) network,” *Physica D: Nonlinear Phenomena*, vol. 404, p. 132306, 2020, doi: 10.1016/j.physd.2019.132306.
- [16] L. Gao, X. Wang, J. Song, and Y. Liu, “Fused GRU with semantic-temporal attention for video captioning,” *Neurocomputing*, vol. 395, no. xxxx, pp. 222–228, 2019, doi: 10.1016/j.neucom.2018.06.096.
- [17] M. Hu *et al.*, “Combination of near-infrared and thermal imaging techniques for the remote and simultaneous measurements of breathing and heart rates under sleep situation,” *PLoS ONE*, vol. 13, no. 1, pp. 1–14, 2018, doi: 10.1371/journal.pone.0190466.